

README по поиску сезонности в акциях

Содержание

1	Итоговые результаты	2
1.1	Результаты по ветке price	2
1.2	Результаты по ветке returns	2
1.3	Основной вывод	3
2	Что именно искалось	3
3	Теоретическая основа: ряды Фурье и FFT	4
3.1	Идея разложения по гармоникам	4
3.2	Переход к дискретному случаю	4
3.3	Быстрое преобразование Фурье	4
3.4	Периодограмма и спектральная мощность	5
3.5	Почему пики спектра связаны с сезонностью	5
3.6	Почему использовался автоэнкодер перед FFT	5
3.7	Что такое signal_share	6
3.8	Что такое peak_share	6
3.9	Интерпретация найденных периодов	6
4	Почему результаты по price и returns различаются	6
4.1	Ряд цен	6
4.2	Ряд доходностей	7
5	Описание кода	7
5.1	Загрузка данных	7
5.2	Ветки анализа	7
5.3	Окна	8
5.4	Автоэнкодер	8
5.5	Целевая функция Optuna	8
5.6	Numba и многопоточность	9
6	Выходные файлы	9
7	Ограничения текущей постановки	9
8	Что можно улучшить дальше	10
9	Заключение	10

1 Итоговые результаты

В рамках эксперимента была реализована схема поиска сезонности в акциях на основе автоэнкодера и спектрального анализа. Рассматривались две независимые ветки анализа:

1. анализ по ряду цен, то есть по нормированному $\log(\text{price})$;
2. анализ по ряду доходностей, то есть по нормированным логарифмическим доходностям.

Основная целевая функция, максимизируемая в Optuna, имела вид:

$$\text{objective} = \text{median}(\text{signal_share}_i),$$

где signal_share_i — доля спектральной мощности, сосредоточенная в сильнейших пиках спектра для i -го тикера.

1.1 Результаты по ветке price

Для ветки **price** были получены наиболее осмысленные результаты.

- Лучшая целевая функция:

$$\text{median}(\text{signal_share}) \approx 0.1949.$$

- Среднее значение:

$$\text{mean}(\text{signal_share}) \approx 0.2068.$$

- Ошибка реконструкции:

$$\text{recon_mse} \approx 0.0145.$$

Это означает, что у ряда цен после реконструкции автоэнкодером в спектре действительно наблюдается выраженная концентрация мощности в нескольких доминирующих периодах.

Наиболее часто встречающийся главный период лежал примерно в диапазоне от 280 до 320 наблюдений, а медианное значение было около 301.5. Для дневных торговых данных это соответствует длинному циклу, близкому к годовому масштабу.

Таким образом, по ветке **price** модель в первую очередь выявила не краткосрочную сезонность уровня недели или месяца, а выраженную долгую низкочастотную компоненту.

1.2 Результаты по ветке returns

Для ветки **returns** результаты оказались значительно менее убедительными.

- Лучшая целевая функция:

$$\text{median}(\text{signal_share}) \approx 0.1350.$$

- Среднее значение:

$$\text{mean}(\text{signal_share}) \approx 0.1389.$$

Ключевое наблюдение состоит в том, что для большинства тикеров главный период оказался около 2.34 наблюдения. Такое значение слишком мало и слишком стабильно повторяется между разными тикерами, поэтому оно, вероятнее всего, отражает не реальную экономическую сезонность, а технический артефакт реконструкции или спектральной обработки.

Поэтому на текущем этапе ветку `returns` нельзя считать надёжным источником интерпретируемой сезонности.

1.3 Основной вывод

На текущем этапе можно сделать следующие выводы:

1. По ряду цен модель действительно находит выраженную низкочастотную компоненту.
2. Эта компонента имеет характер длинного цикла, а не классической краткосрочной календарной сезонности.
3. По ряду доходностей результаты пока выглядят артефактными и требуют переработки постановки задачи.

2 Что именно искалось

Важно подчеркнуть, что в данной постановке задача состояла не в поиске классической календарной сезонности вида “эффект дня недели” или “эффект месяца”, а в поиске **доминирующих циклических компонент** в полном ряду тикера.

Алгоритм работал так:

1. Для каждого тикера брался весь доступный временной ряд.
2. Ряд преобразовывался либо в нормированный $\log(\text{price})$, либо в нормированные логарифмические доходности.
3. Из ряда строились скользящие окна длины $W = 90$.
4. Автоэнкодер обучался реконструировать эти окна.
5. После этого из реконструированных окон собирался полный восстановленный ряд.
6. На полном восстановленном ряду рассчитывался спектр с помощью FFT.
7. По спектру определялись доминирующие периоды.

Следовательно, сезонность искалась **на всей длине ряда**, а не внутри отдельного года, месяца или недели.

3 Теоретическая основа: ряды Фурье и FFT

3.1 Идея разложения по гармоникам

Любой достаточно регулярный сигнал можно представить как сумму синусоидальных компонент разных частот. В непрерывном случае классический ряд Фурье имеет вид

$$f(t) = \frac{a_0}{2} + \sum_{k=1}^{\infty} \left(a_k \cos\left(\frac{2\pi kt}{T}\right) + b_k \sin\left(\frac{2\pi kt}{T}\right) \right),$$

где:

- T — базовый период;
- a_k, b_k — коэффициенты ряда Фурье;
- каждая гармоника соответствует своей частоте.

Смысл этого разложения состоит в том, что сложный сигнал можно представить как сумму простых колебаний.

3.2 Переход к дискретному случаю

Для временных рядов акций наблюдения заданы в дискретные моменты времени. Поэтому применяется дискретное преобразование Фурье (DFT). Для ряда

$$x_0, x_1, \dots, x_{N-1}$$

дискретное преобразование Фурье определяется формулой

$$X_k = \sum_{n=0}^{N-1} x_n e^{-2\pi i kn/N}, \quad k = 0, 1, \dots, N-1.$$

Здесь:

- x_n — значение сигнала в момент n ;
- X_k — комплексная амплитуда k -й частоты;
- модуль $|X_k|$ показывает силу соответствующей частотной компоненты.

3.3 Быстрое преобразование Фурье

Прямой расчёт DFT требует порядка $O(N^2)$ операций, что дорого для длинных рядов. Поэтому применяется FFT — Fast Fourier Transform, то есть быстрый алгоритм вычисления DFT, имеющий сложность порядка

$$O(N \log N).$$

В коде использовалась функция `numpy.fft.rfft`, поскольку входной ряд вещественный, и достаточно только неотрицательных частот.

3.4 Периодограмма и спектральная мощность

После вычисления преобразования Фурье для каждой частоты оценивается мощность спектра. В используемой реализации она рассчитывалась как

$$\text{power}(f_k) = \frac{|X_k|^2}{N}.$$

Чем больше мощность на некоторой частоте, тем сильнее соответствующая циклическая компонента в сигнале.

Далее частота переводится в период по формуле

$$\text{period}_k = \frac{1}{f_k}.$$

Если данные дневные по торговым наблюдениям, то период измеряется в числе торговых дней.

3.5 Почему пики спектра связаны с сезонностью

Если в ряду есть повторяющийся паттерн, например цикл длиной примерно T наблюдений, то в спектре возникает выраженный пик около частоты

$$f = \frac{1}{T}.$$

Следовательно:

- сильный пик спектра означает наличие заметной циклической компоненты;
- положение пика определяет длину периода;
- несколько сильных пиков означают, что в сигнале присутствует несколько наложенных циклов.

3.6 Почему использовался автоэнкодер перед FFT

Финансовые временные ряды содержат много шума, выбросов и высокочастотной нестационарности. Если применять FFT непосредственно к исходному ряду, то спектр может быть перегружен шумовыми компонентами.

Автоэнкодер использовался как инструмент сглаживания и извлечения устойчивой структуры сигнала. Он обучался реконструировать локальные окна ряда. В результате получался более гладкий восстановленный ряд, для которого спектр оказывался более интерпретируемым.

Идея была следующей:

1. исходный ряд режется на окна длины W ;
2. автоэнкодер учится восстанавливать окна;
3. реконструированные окна усредняются в общий восстановленный ряд;
4. FFT применяется уже к восстановленному ряду.

3.7 Что такое `signal_share`

После построения спектра находились сильнейшие пики мощности. Пусть у нас есть полный спектр мощности

$$\{p_1, p_2, \dots, p_m\},$$

а также множество индексов сильнейших K пиков.

Тогда доля сигнала определялась как

$$\text{signal_share} = \frac{\sum_{j \in \text{Top-K peaks}} p_j}{\sum_{i=1}^m p_i}.$$

Это показатель того, какая часть всей спектральной мощности сосредоточена в нескольких доминирующих циклах.

Если значение велико, значит спектр собран в несколько выраженных периодов. Если мало, значит мощность размазана по спектру и ярко выраженной сезонной структуры нет.

3.8 Что такое `peak_share`

Для каждого отдельного пика дополнительно рассчитывалась величина

$$\text{peak_share} = \frac{\text{peak_power}}{\text{total_power}}.$$

Она показывает, насколько один конкретный период доминирует над всем спектром.

3.9 Интерпретация найденных периодов

Поскольку анализ проводился на торговых наблюдениях, период интерпретируется в торговых днях. Приблизительно:

- 5 — торговая неделя;
- 21 — торговый месяц;
- 63 — квартал;
- 126 — полугодие;
- 252 — торговый год.

Полученные в ветке `price` периоды около 280–320 наблюдений означают длинную годоподобную низкочастотную компоненту.

4 Почему результаты по `price` и `returns` различаются

4.1 Ряд цен

Ряд цен содержит:

- долгосрочный тренд;

- медленные колебания;
- режимные изменения;
- циклы большого масштаба.

Поэтому FFT на ряде цен чаще находит низкочастотные компоненты. Именно это и наблюдалось в результатах.

4.2 Ряд доходностей

Логарифмические доходности ближе к шумовому процессу и намного слабее содержат долгосрочную структуру. В результате:

- спектр становится менее стабильным;
- ярче проявляются артефакты;
- доминирующий период может оказаться неинтерпретируемым.

Именно поэтому появление устойчивого периода около 2.34 наблюдения для множества тикеров рассматривается как подозрительный результат.

5 Описание кода

5.1 Загрузка данных

Данные загружались по той же логике, что и в коде кластеризации:

- сначала проверяется наличие файла `data/prices_all.csv`;
- если его нет, собираются все CSV из каталога `data/`;
- автоматически выбирается колонка `Adj Close`, а если её нет — `Close`;
- сохраняются только тикеры, начинающиеся с глобальной первой даты в наборе данных.

5.2 Ветки анализа

Реализованы две независимые ветки:

1. **price**: анализ по нормированному $\log(\text{price})$;
2. **returns**: анализ по нормированным логарифмическим доходностям.

Для каждой ветки запускаются:

- собственная оптимизация гиперпараметров;
- собственный автоэнкодер;
- собственный спектральный анализ;
- собственные выходные файлы.

5.3 Окна

Если длина ряда равна N , а длина окна равна W , то число окон определяется как

$$N_{\text{windows}} = N - W + 1.$$

Каждое окно имеет длину $W = 90$.

5.4 Автоэнкодер

Автоэнкодер представляет собой полносвязную нейронную сеть. Его архитектура включала:

- входной слой размерности W ;
- несколько скрытых слоёв с ReLU-активацией;
- латентное пространство размерности `latent_dim`;
- симметричный декодер.

Гиперпараметры, оптимизируемые через Optuna:

- `latent_dim`;
- `hidden_dim`;
- `n_layers`;
- `dropout`;
- `batch_size`;
- `n_epochs`;
- `lr`.

5.5 Целевая функция Optuna

Для каждого trial:

1. обучался автоэнкодер;
2. для всех тикеров строился восстановленный ряд;
3. вычислялся спектр;
4. определялся `signal_share`;
5. бралась медиана по тикерам.

Именно это и было целевой функцией:

$$\text{objective} = \text{median}(\text{signal_share}_i).$$

5.6 Numba и многопоточность

Поскольку этап overlap-склейки оказался узким местом, он был вынесен в функцию на numba с использованием:

- @njit;
- parallel=True;
- prange.

Параллелизация шла по позициям итогового ряда. Для каждой позиции независимо вычислялось среднее по всем окнам, покрывающим эту точку.

6 Выходные файлы

Для каждой ветки формировались следующие файлы:

- *_autoencoder_best.pt — веса лучшей модели;
- *_best_params.json — лучшие гиперпараметры и итоговые метрики;
- *_optuna_trials.csv — таблица всех trial Optuna;
- *_fft_seasonality_ae.xlsx — summary по найденным периодам;
- *_fft_spectra_reconstructed_ae.csv — спектры по тикерам;
- *_fft_spectra_reconstructed_ae.pdf — графики спектров;
- *_ae_original_vs_recon_timeseries.csv — исходные и реконструированные ряды;
- *_ae_original_vs_recon_timeseries.pdf — графики исходных и реконструированных рядов.

7 Ограничения текущей постановки

1. Поиск шёл по всей длине ряда, а не по отдельным календарным периодам.
2. Найденные циклы не обязательно являются классической сезонностью; они могут отражать длинные режимные компоненты.
3. Ветка `returns` в текущей версии не даёт убедимой интерпретируемой сезонности.
4. FFT хорошо выявляет циклические компоненты, но не гарантирует, что найденный период имеет именно экономическую природу.

8 Что можно улучшить дальше

1. Искать сезонность внутри года, а не по всей истории сразу.
2. Проверять только заранее интересующие частоты, например около 5, 21, 63, 126, 252.
3. Для ускорения считать `objective` не по всем тикерам на каждом `trial`, а по случайной подвыборке.
4. Для ветки `returns` изменить постановку задачи, так как текущая версия ловит артефактный период.
5. Добавить сравнительный анализ сезонности по кластерам, полученным ранее.

9 Заключение

Проведённый эксперимент показал, что предложенная схема “автоэнкодер + FFT” способна выявлять в ряде цен акций выраженные длинные циклические компоненты. Наиболее устойчивый результат получен для анализа по ценам, где доминируют низкочастотные периоды порядка нескольких сотен торговых наблюдений.

В то же время анализ по доходностям в текущей постановке пока не дал интерпретируемой сезонности и требует дальнейшей доработки.

Следовательно, на данном этапе подход можно считать полезным в первую очередь как инструмент поиска доминирующих долгих циклов в динамике цен, но не как окончательно настроенный метод извлечения классической календарной сезонности.